
Universidad Autónoma de Nuevo León
Facultad de Ciencias Físico Matemáticas

Producto Integrador de Aprendizaje

Análisis de Créditos de Exportación del Export-Import Bank de los EE.UU.

Alumno: Irving Joseafath Rodríguez González

Materia: Minería de Datos

Profesor: José Hernández

Dataset: Export Credit Approvals (aproxCreditos.csv)

Fecha: Mayo 2026

Índice

1. Introducción y Descripción del Dataset	2
2. El Hallazgo Principal	2
3. Estadística Descriptiva	3
3.1. Distribución por Programa y País	3
3.1.1. Análisis por País	4
3.2. Análisis por Plazo (Term)	4
3.3. Caso Especial: Luxembourg	5
4. Evidencia Estadística	5
4.1. Prueba ANOVA	5
4.2. Prueba T-Test	6
5. Regresión Lineal	6
6. Técnicas Avanzadas	8
6.1. Clasificación con K-Nearest Neighbors (KNN)	8
6.2. Clustering con K-Means	9
7. Integración de Resultados	10
8. Conclusiones	11

1. Introducción y Descripción del Dataset

El presente reporte analiza el conjunto de datos de **aprobación de créditos de exportación** del Export-Import Bank de los Estados Unidos (Ex-Im Bank), institución federal que facilita el financiamiento de exportaciones estadounidenses hacia mercados internacionales.

El dataset contiene **50,249 registros** con las siguientes variables de análisis:

Cuadro 1: Variables del dataset utilizadas en el análisis

Variable	Tipo	Descripción
Program	Categorica	Tipo de instrumento financiero (Insurance, Working Capital, Guarantee, Loan)
Term	Categorica	Plazo del crédito (Short, Medium, Long Term)
Country	Categorica	País destino de la exportación (150 países)
Deal_Cancelled	Binaria	Si el trato fue cancelado (Yes/No)
Approved_Declined_Amount	Numérica	Monto aprobado por el Ex-Im Bank (USD)
Disbursed_Shipped_Amount	Numérica	Monto efectivamente desembolsado (USD)
Decision_Year/Month/Day	Temporal	Fecha de decisión del crédito
Product_Description	Texto	Descripción del producto exportado

2. El Hallazgo Principal

Hallazgo central: El tipo de programa financiero (**Program**) es el factor que mejor predice el monto de un crédito de exportación, con un poder predictivo del **83 %** sobre el monto desembolsado. Contrariamente a lo que podría esperarse, el país de destino casi no influye en el monto del crédito ($R^2 = 0.004$), siendo el instrumento financiero y el plazo los verdaderos determinantes.

Este hallazgo se sustenta en una diferencia radical entre los promedios de cada programa:

Cuadro 2: Monto promedio aprobado por tipo de programa

Programa	Monto Promedio (USD)	Registros	Proporción
Loan	\$119,588,300	352	0.7 %
Guarantee	\$40,177,020	2,738	5.4 %
Working Capital	\$4,699,023	5,781	11.5 %
Insurance	\$835,986	41,378	82.3 %

El programa *Loan* maneja en promedio **143 veces más** que *Insurance*, a pesar de representar menos del 1 % de los registros.

3. Estadística Descriptiva

3.1. Distribución por Programa y País

El análisis descriptivo reveló patrones geográficos significativos en el uso de los instrumentos financieros:

Cuadro 3: Distribución de programas por origen geográfico

Programa	EE.UU.	Extranjero
Insurance	1	41,377
Working Capital	5,781	0
Guarantee	45	2,693
Loan	11	341

Observación clave: El programa *Working Capital* opera *exclusivamente* dentro de Estados Unidos (5,781 registros domésticos, 0 extranjeros), mientras que *Insurance* es casi exclusivo del mercado exterior (41,377 de 41,378 registros).





Figura 1: Distribución del monto aprobado por tipo de programa (escala logarítmica)

3.1.1. Análisis por País

La distribución de montos por país refleja los patrones geográficos del financiamiento. Los países con mayor monto promedio aprobado concentran operaciones del tipo *Loan* y *Guarantee*, mientras que los mercados con mayor volumen de transacciones corresponden a *Insurance* de menor cuantía.



(a) Top 10 países por monto aprobado promedio

(b) Top 10 países por monto desembolsado promedio

Figura 2: Comparativa de montos promedio por país destino

3.2. Análisis por Plazo (Term)

Cuadro 4: Distribución de plazos en programa Loan vs. resto

Plazo	Loan	Otros programas
Long Term	344 (97.7 %)	1,180 (2.5 %)
Medium Term	8 (2.3 %)	2,855 (6.1 %)
Short Term	0 (0 %)	45,862 (91.4 %)

El programa *Loan* opera casi exclusivamente en *Long Term* (97.7 %), confirmando que los préstamos directos financian proyectos de infraestructura de larga duración.




Figura 3: Monto aprobado promedio según plazo del crédito

3.3. Caso Especial: Luxembourg

Luxembourg presenta un perfil estadísticamente atípico respecto al resto del mundo: el 63 % de sus créditos son *Guarantee* (vs. 5.4 % mundial) y el 68 % son *Long Term* (vs. 3.4 % mundial), lo cual es consistente con su rol como **hub financiero europeo** que intermedia grandes proyectos de infraestructura.

4. Evidencia Estadística

4.1. Prueba ANOVA

Se aplicó la prueba ANOVA de tipo II para determinar si las variables categóricas generan diferencias significativas en los montos. El umbral de significancia utilizado fue $p < 0,005$.

Cuadro 5: Resultados ANOVA – Variable dependiente: Monto Aprobado

Factor	F	p-value	Conclusión
Program	1,960.21	≈ 0	Diferencias significativas
Country	39.15	≈ 0	Diferencias significativas
Term	4,858.18	≈ 0	Diferencias significativas

Cuadro 6: Resultados ANOVA – Variable dependiente: Monto Desembolsado

Factor	F	p-value	Conclusión
Program	1,966.32	≈ 0	Diferencias significativas
Country	23.10	≈ 0	Diferencias significativas
Term	5,578.99	≈ 0	Diferencias significativas

La variable **Term** presenta el estadístico F más alto ($F = 5,578.99$ sobre el monto desembolsado), indicando que el plazo del crédito es **el factor con mayor capacidad discriminante** entre grupos.

4.2. Prueba T-Test

Para comparar pares específicos de grupos se aplicó T-Test de Welch sobre los dos grupos con mayor promedio de cada variable:

Cuadro 7: Resultados T-Test entre grupos de mayor promedio

Variable	Grupo 1	Grupo 2	Resultado
Program	Loan	Guarantee	Diferencias significativas
Country	Mozambique	Papua New Guinea	Sin diferencias
Country	Papua New Guinea	Luxembourg	Sin diferencias
Term	Long Term	Medium Term	Diferencias significativas

La ausencia de diferencias entre Luxembourg y Papua New Guinea resulta estadísticamente notable: aunque operan con lógicas completamente distintas (hub financiero vs. país receptor), sus montos promedio no son distinguibles por T-Test, lo que indica alta variabilidad dentro de cada grupo.


5. Regresión Lineal

Se generaron modelos de regresión lineal para cuantificar las relaciones entre variables. El coeficiente de determinación R^2 indica qué porcentaje de la varianza es explicado por el modelo.

Cuadro 8: R^2 obtenidos en los modelos de regresión lineal

Variable X	Variable Y	R^2	Interpretación
Program	Disbursed_Shipped_Amount	0.8302	Excelente ajuste
Program	Approved_Declined_Amount	0.4960	Ajuste moderado
Term	Decision_Month	0.5494	Ajuste moderado
Term	Decision_Year	0.5452	Ajuste moderado
Term	Decision_Day	0.5417	Ajuste moderado
Country	Approved_Declined_Amount	0.0080	Sin relación lineal
Term	Approved_Declined_Amount	-0,2326	Relación no lineal
Term	Disbursed_Shipped_Amount	-0,6865	Relación no lineal

Interpretación del modelo principal: El modelo $\text{Program} \rightarrow \text{Disbursed_Shipped_Amount}$ alcanza un $R^2 = 0,8302$, lo cual significa que conociendo únicamente el tipo de programa se puede explicar el **83 %** de la variación en los montos desembolsados.

Figura 4: Regresión lineal: Programa vs. Monto Desembolsado promedio ($R^2=0.8740$)




Figura 5: Dispersión entre monto aprobado y monto desembolsado

El R^2 negativo en **Term** sobre los montos confirma que, aunque el ANOVA detectó diferencias reales entre grupos de plazo, la relación no es lineal: *Long Term*, *Medium Term* y *Short Term* tienen montos muy distintos pero no siguen una progresión ordenada al convertirlos a índices numéricos.

6. Técnicas Avanzadas

6.1. Clasificación con K-Nearest Neighbors (KNN)

Se implementó KNN desde cero (sin *sklearn*) para clasificar créditos según su tipo de programa basándose en los montos aprobado y desembolsado.

- **Features:** `Approved_Declined_Amount`, `Disbursed_Shipped_Amount`
- **Label:** `Program` (4 clases)
- **Parámetro k:** 10 vecinos
- **Métrica:** Distancia euclidiana

Resultado de clasificación: Para un crédito con monto aprobado de \$500,000 y monto desembolsado de \$300,000, el modelo clasificó el crédito como:

Clasificación: Insurance

Este resultado es coherente con los datos: montos menores a \$1,000,000 corresponden típicamente al programa *Insurance*, cuyo promedio es \$835,986. La clasificación fue po-

sible gracias al elevado poder discriminante que el ANOVA y la regresión lineal habían identificado previamente en los montos.




Figura 6: Dispersión de montos coloreada por tipo de programa (espacio de clasificación KNN)

6.2. Clustering con K-Means

Se aplicó K-Means con $k = 4$ sobre las dos variables numéricas de monto, utilizando una muestra de 500 registros para optimizar el tiempo de cómputo. El algoritmo se implementó desde cero con distancia euclidiana y convergencia iterativa.

Configuración del modelo:

- **Variables:** `Approved_Declined_Amount`, `Disbursed_Shipped_Amount`
- **k = 4** grupos (correspondiente a los 4 programas)
- **Máximo de iteraciones:** 15
- **Inicialización:** aleatoria con semilla fija (`random_state=42`)

Los 4 clusters identificados por el algoritmo corresponden naturalmente a los 4 programas del dataset:

Cuadro 9: Correspondencia entre clusters K-Means y programas

Cluster	Color	Rango de montos	Programa equivalente
0	Azul	< \$1M (denso)	Insurance
3	Naranja	\$1M – \$10M (disperso)	Working Capital
1	Verde	\$10M – \$200M	Guarantee
2	Rojo	> \$200M (aislado)	Loan

El resultado del clustering **validó de forma no supervisada** los hallazgos previos: los 4 grupos emergen naturalmente de los datos sin usar las etiquetas de **Program**, confirmando que los montos por sí solos son suficientes para separar los instrumentos financieros.



(a) K-Means con $k = 4$ clusters(b) K-Means con $k = 3$ clusters

Figura 7: Resultados del clustering K-Means sobre los montos aprobado y desembolsado. Con $k = 4$ los grupos corresponden a los 4 programas; con $k = 3$ la separación es análoga a los tres plazos del crédito.

7. Integración de Resultados

Las cinco técnicas aplicadas convergen hacia las mismas conclusiones:

Cuadro 10: Convergencia de evidencia entre técnicas

Técnica	Conclusión
Estadística descriptiva	Los promedios difieren hasta 143x entre programas (\$835K vs \$119M)
ANOVA	Diferencias estadísticamente significativas en todos los factores ($p \approx 0$)
Regresión Lineal	Program explica el 83 % del monto desembolsado ($R^2=0.83$)
KNN	Créditos de \$500K clasificados correctamente como <i>Insurance</i>
K-Means	4 clusters emergen naturalmente, correspondientes a los 4 programas

8. Conclusiones

1. **El tipo de programa es el predictor dominante.** Con un $R^2=0.8302$ en regresión lineal y $F=1,966$ en ANOVA, el programa financiero explica por sí solo el 83 % de la variación en montos desembolsados, superando ampliamente al país de destino ($R^2=0.004$) y al plazo en relación lineal.
2. **El plazo discrimina mejor que el programa en varianza total.** Aunque la regresión lineal de *Term* sobre montos produce R^2 negativos (relación no lineal), su estadístico $F=5,578$ en ANOVA es el más alto del análisis, indicando que la diferencia entre *Long Term* y *Short Term* en términos absolutos es la más grande del dataset.
3. **El país de destino no determina el monto.** Con $R^2=0.004$ en regresión, el T-Test confirmó que incluso países con perfiles tan distintos como Luxembourg y Papua New Guinea no muestran diferencias estadísticamente significativas en montos ($p \geq 0.005$).
4. **K-Means validó los hallazgos de forma no supervisada.** Los 4 clusters emergen de los datos sin conocer las etiquetas, confirmando que la estructura de los programas está genuinamente codificada en los montos.
5. **El Ex-Im Bank opera en dos mercados completamente distintos.** *Insurance* domina las operaciones internacionales de pequeñas y medianas empresas (82.3 % de registros, \$835K promedio), mientras que *Loan* financia mega-proyectos de infraestructura de largo plazo (\$119M promedio, 97.7 % en *Long Term*).